



Modelo preditivo para identificação de clientes detratores de NPS

Grupo: Avatares


Arthur • Cassio • Felipe • Fernanda • Gabriel • Kaylan • Luiza • Pedro

A identificação de passageiros detratores de NPS

ocorre de forma majoritariamente reativa, somente após o cliente responder à pesquisa com uma nota baixa (0 a 6).




Trajetória do projeto



Evolução da pergunta: “o que explica a detração?” para “como pontuar risco de detração no momento certo?”

Preparação dos dados: base integrada e auditável



Decisões: sem dropna global; nulos estruturais preservados; outliers mantidos e tratados no pipeline.

Split antes de qualquer ajuste estatístico evita vazamentos entre treino e teste.

Modelagem e features: só entra o que existe em t_score

Permitidas no score pós-viagem

PERFIL_TUDOAZUL

VOO_TIPO

TIPO_ENTRETENIMENTO

CANAL_COMPRA

SEGMENTO

ATRASSO / CANCELAMENTO

TEMPO_VOO

QTDE_VIAGENS_12M

Proibidas como features

NPS_PRINCIPAL

DETRATOR

CATEGORIA_NPS

NPS_* de etapas

SUB_* da pesquisa

identificadores


Contrato temporal

reserva – partida – chegada – t_score – pesquisa – resposta NPS

Regra: valor elegível apenas se disponível de forma confiável antes ou no momento do score.

Risco evitado: modelo “ótimo” no notebook, mas inaplicável na operação por usar informação da própria resposta.


Primeiro modelo: score de risco pós-viagem



POR QUE GRADIENT BOOSTING?

A detração depende da combinação entre fatores de perfil e operação. O Gradient Boosting captura essas interações melhor que um modelo linear e foi superior em todas as divisões de validação.

Métricas e resultados: avaliar a classe que importa



Target desbalanceado
20,44% detratores

Precisão
Meta: $\geq 0,40$
Resultado: 0,5386

ROC-AUC
Meta: $\geq 0,75$
Resultado: 0,7482

Recall
meta $\geq 0,70$
Resultado: 0,4464

Métrica primária: revocação da classe Detrator. Para o negócio, deixar de acionar um cliente que detrataria tende a ser mais custoso que acionar um falso positivo.

Discussão: o que os dados já indicam

Atraso é driver e viés de resposta

Ponto crítico: janela de 20–30 minutos aparece como mudança de regime no risco de detração.


Cancelamento no mesmo dia: maior risco observado

Associação robusta, mas sem causalidade: falta controlar causa/tipo do cancelamento.

Cliente fidelizado tem expectativa maior

Interações importam: tier × atraso deve ser lido junto, não como efeito isolado.

Integração documentação/Colab: rastreabilidade do resultado



Boa prática adotada: o slide não traz “número solto”. Cada métrica deve apontar para célula/notebook e seção correspondente da documentação.

Revisões e conclusão: o que amadureceu nesta sprint

Target

Detrator vs. não detrator validado

Leakage

NPS_* e SUB_* removidos do X

Schema

Allowlist explícita para score pós-viagem

Validação

Partição temporal e atenção a cliente recorrente

Negócio

Score prioriza ação, não automatiza decisão

Conclusão da sprint: saímos de uma base integrada para um pipeline com contrato temporal, alvo validado e primeiro modelo mensurável.

Próximos passos

1. Definir métricas comparativas dos modelos candidatos

2. Fazer modelos mais aprimorados em relação ao inicial

3. Comparar ao menos três modelos candidatos

Objetivo da próxima entrega: transformar o primeiro candidato em uma comparação robusta e acionável para decisão do parceiro.

EQUIPE



Arthur Gonçalves



Cassio Costa



Fernanda Steiner



Felipe Estrada



Gabriel Pimentel



Kaylan Sathler



Luiza Cresci



Pedro Leal

Perguntas

Abertura para dúvidas da Azul e banca

Resumo em uma frase: o Safira prioriza, com base em dados operacionais, quem tem maior risco de responder como detrator.